


# Kuggle

2020\_02 Kuggle 정규세션\_W6

2020.10.27  
발표자: 정성준



# CONTENTS

## 01 Linear Discriminant Analysis(LDA) 개요


- 선형판별분석
- LDA vs PCA

## 02 LDA 접근

- Fisher's linear discriminant
- Bayesian rule

## 03 LDA 실습

- Sklearn, iris dataset을 이용한 실습




# 01 Linear Discriminant Analysis(LDA) 개요

## - LDA, Linear Discriminant Analysis

:클래스간 분산(between-class scatter)과 클래스내 분산(within-class scatter)의 비율을 최대화하는 방식으로 데이터에 대한 특징 벡터의 차원을 축소하는 방법

- LDA는 아래와 같은 두 가지 성질을 가진 벡터를 찾는다.

- 1) 데이터 포인트들을 투영시켰을 때 각 클래스에 속하는 투영들의 평균간의 거리의 합이 최대가 되게 하는 벡터. 다른 말로, **클래스 간(between-class)의 거리가 최대가 되게 하는 벡터.**
- 2) 데이터 포인트들을 투영시켰을 때 클래스 내의 투영들의 분산이 최소가 되게 하는 벡터. 다른 말로, **클래스 내(within-class)의 분산이 최소가 되게 하는 벡터.**



# 01 Linear Discriminant Analysis(LDA) 개요

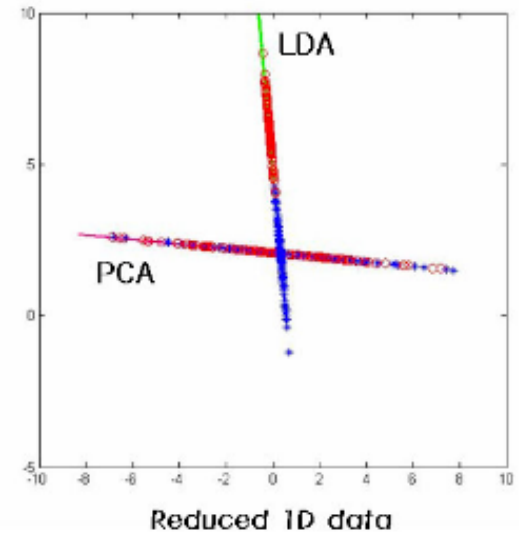

## - LDA vs PCA

### 1. 선형판별분석(LDA)

: 데이터의 최적 분류(best discrimination between classes)의 관점에서 차원을 축소하는 방법

### 2. 주성분분석(PCA)

: 데이터의 최적 표현(best description of the data in its entirety)의 관점에서 데이터를 축소하는 방법



# CONTENTS

## 01 Linear Discriminant Analysis(LDA) 개요


- 선형판별분석
- LDA vs PCA

## 02 LDA의 이해

- Fisher's linear discriminant
- Bayesian rule

## 03 LDA 실습

- Sklearn, iris dataset을 이용한 실습



## 02 LDA의 이해

### - Fisher's linear discriminant

:클래스 내 분산(within-class scatter)으로 평균 간의 차이를 정규화하여 목적 함수로 표현하고, 이를 최대화하는 방법

:Fisher의 선형 판별식은 목적 함수를 최대화하는 선형 변환행렬  $W$ 를 찾아내는 것  $\rightarrow W$ 라는 변환 행렬은 같은 클래스의 표본들은 인접하게 사영을 취하고, 다른 클래스간의 사영은 가능한 중심이 멀리 떨어지도록 변환시키는 행렬을 의미

- 사영 표본의 각 클래스에 대한 분산

$$\tilde{s}_1^2 = \sum_{y \in \omega_1} (y - \tilde{\mu}_1)^2$$

- 사영 표본의 클래스내 분산

$$(\tilde{s}_1^2 + \tilde{s}_2^2)$$

- 목적 함수

$$J(W) = \frac{|\tilde{\mu}_1 - \tilde{\mu}_2|^2}{(\tilde{s}_1^2 + \tilde{s}_2^2)}$$

## 02 LDA의 이해

### - Fisher's linear discriminant

: 수학적 이해

$L$ : 클래스 수

$N_i$ : 클래스  $i$  내 샘플의 개수

$N$ : 전체 샘플의 개수

$x_j^{(i)}$ : 클래스  $i$  내  $j$  번째 샘플

$$N = N_1 + N_2 + \dots + N_L$$

클래스 1부터 클래스  $L$  까지의 데이터포인트들을 나열하면 아래와 같다


$$x_1^{(1)}, x_2^{(1)}, \dots, x_{N_1}^{(1)}, x_1^{(2)}, x_2^{(2)}, \dots, x_{N_2}^{(2)}, \dots, x_1^{(L)}, x_2^{(L)}, \dots, x_{N_L}^{(L)}$$

클래스 1부터 클래스  $L$  까지의 데이터포인트들을 벡터  $v$ 에 사상(linear map)하면 다음과 같다

$$v^T x_1^{(1)}, v^T x_2^{(1)}, \dots, v^T x_{N_1}^{(1)}, v^T x_1^{(2)}, v^T x_2^{(2)}, \dots, v^T x_{N_2}^{(2)}, \dots, v^T x_1^{(L)}, v^T x_2^{(L)}, \dots, v^T x_{N_L}^{(L)}$$

사상한 벡터들을 가지고 두 가지를 구한다

- 1) 클래스 간의 거리의 합
- 2) 각 클래스 내의 분산의 합



## 02 LDA의 이해

### - Fisher's linear discriminant

#### 1) 클래스 간의 거리의 합

클래스  $i$ 에 속하는 데이터 포인트들의 사상들의 평균

$$\begin{aligned}\overline{m_i} &= \frac{1}{N_i} \sum_{j=1}^{N_i} v^T x_j^{(i)} & m_i &= \frac{1}{N_i} \sum_{j=1}^{N_i} x_j^{(i)} \\ &= v^T \left( \frac{1}{N_i} \sum_{j=1}^{N_i} x_j^{(i)} \right) \\ &= v^T m_i\end{aligned}$$

클래스 간의 거리구하기

$$\begin{aligned}& \frac{N_1}{N} \frac{N_2}{N} (\overline{m_1} - \overline{m_2})^2 + \frac{N_1}{N} \frac{N_3}{N} (\overline{m_1} - \overline{m_3})^2 + \dots + \frac{N_1}{N} \frac{N_L}{N} (\overline{m_1} - \overline{m_L})^2 \\ & + \frac{N_2}{N} \frac{N_3}{N} (\overline{m_2} - \overline{m_3})^2 + \frac{N_2}{N} \frac{N_4}{N} (\overline{m_2} - \overline{m_4})^2 + \dots + \frac{N_2}{N} \frac{N_L}{N} (\overline{m_2} - \overline{m_L})^2 \\ & \vdots \\ & + \frac{N_7}{N} \frac{N_7}{N} (\overline{m_7} - \overline{m_7})^2 + \frac{N_7}{N} \frac{N_7}{N} (\overline{m_7} - \overline{m_7})^2 + \dots + \frac{N_{L-1}}{N} \frac{N_L}{N} (\overline{m_{L-1}} - \overline{m_L})^2\end{aligned} \longrightarrow \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\overline{m_i} - \overline{m_j})^2$$

$L$ : 클래스 수

$N_i$ : 클래스  $i$  내 샘플의 개수

$N$ : 전체 샘플의 개수

$x_j^{(i)}$ : 클래스  $i$  내  $j$  번째 샘플



## 02 LDA의 이해

### - Fisher's linear discriminant

#### 1) 클래스 간의 거리의 합

클래스 간의 거리구하기

$$\begin{aligned}
 & \frac{N_1}{N} \frac{N_2}{N} (\overline{m_1} - \overline{m_2})^2 + \frac{N_1}{N} \frac{N_3}{N} (\overline{m_1} - \overline{m_3})^2 + \dots + \frac{N_1}{N} \frac{N_L}{N} (\overline{m_1} - \overline{m_L})^2 \\
 & + \frac{N_2}{N} \frac{N_3}{N} (\overline{m_2} - \overline{m_3})^2 + \frac{N_2}{N} \frac{N_4}{N} (\overline{m_2} - \overline{m_4})^2 + \dots + \frac{N_2}{N} \frac{N_L}{N} (\overline{m_2} - \overline{m_L})^2 \\
 & \vdots \\
 & + \frac{N_7}{N} \frac{N_7}{N} (\overline{m_7} - \overline{m_7})^2 + \frac{N_7}{N} \frac{N_7}{N} (\overline{m_7} - \overline{m_7})^2 + \dots + \frac{N_{L-1}}{N} \frac{N_L}{N} (\overline{m_{L-1}} - \overline{m_L})^2
 \end{aligned}
 \longrightarrow \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\overline{m_i} - \overline{m_j})^2$$

$$\begin{aligned}
 & \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\overline{m_i} - \overline{m_j})^2 \\
 & = \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\overline{m_i} - \overline{m_j})(\overline{m_i} - \overline{m_j})^T \\
 & = \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (v^T m_i - v^T m_j)(v^T m_i - v^T m_j)^T \quad (\because \overline{m_i} = v^T m_i) \\
 & = \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} v^T (m_i - m_j)(m_i - m_j)^T v \\
 & = v^T \left( \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \right) v \\
 & = v^T S_b^{LDA} v \longrightarrow \text{Between-class scatter matrix}
 \end{aligned}$$

$L$ : 클래스 수

$N_i$ : 클래스  $i$  내 샘플의 개수

$N$ : 전체 샘플의 개수

$x_j^{(i)}$ : 클래스  $i$  내  $j$  번째 샘플

## 02 LDA의 이해

### - Fisher's linear discriminant

#### 1) 클래스 간의 거리의 합

클래스 간의 거리구하기

$$\begin{aligned}
 & \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\bar{m}_i - \bar{m}_j)^2 \\
 &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (\bar{m}_i - \bar{m}_j)(\bar{m}_i - \bar{m}_j)^T \\
 &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (v^T m_i - v^T m_j)(v^T m_i - v^T m_j)^T \quad (\because \bar{m}_i = v^T m_i) \\
 &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} v^T (m_i - m_j)(m_i - m_j)^T v \\
 &= v^T \left( \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \right) v \\
 &= v^T S_b^{LDA} v \quad \longrightarrow \text{Between-class scatter matrix}
 \end{aligned}$$

$$\begin{aligned}
 S_b^{LDA} &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \\
 &= \sum_{i=1}^L \frac{N_i}{N} (m_i - m_0)(m_i - m_0)^T
 \end{aligned}$$

$L$ : 클래스 수  
 $N_i$ : 클래스  $i$  내 샘플의 개수  
 $N$ : 전체 샘플의 개수  
 $x_j^{(i)}$ : 클래스  $i$  내  $j$  번째 샘플

$$\begin{aligned}
 S_b^{LDA} &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \\
 &= \frac{1}{2} \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \\
 &= \frac{1}{2} \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i^T - m_j^T) \\
 &= \frac{1}{2} \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i m_i^T - m_i m_j^T - m_j m_i^T + m_j m_j^T) \\
 &= \frac{1}{2} \left( \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} m_i m_i^T - \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} m_i m_j^T \right. \\
 &\quad \left. - \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} m_j m_i^T + \sum_{i=1}^L \sum_{j=1}^L \frac{N_i}{N} \frac{N_j}{N} m_j m_j^T \right) \\
 &= \frac{1}{2} \left( \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T \sum_{j=1}^L \frac{N_j}{N} - \sum_{i=1}^L \frac{N_i}{N} m_i \sum_{j=1}^L \frac{N_j}{N} m_j^T \right. \\
 &\quad \left. - \sum_{i=1}^L \frac{N_i}{N} m_i^T \sum_{j=1}^L \frac{N_j}{N} m_j + \sum_{i=1}^L \frac{N_i}{N} \sum_{j=1}^L \frac{N_j}{N} m_j m_j^T \right) \\
 &= \frac{1}{2} \left( \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - \sum_{i=1}^L \frac{N_i}{N} m_i \sum_{j=1}^L \frac{N_j}{N} m_j^T \right. \\
 &\quad \left. - \sum_{i=1}^L \frac{N_i}{N} m_i^T \sum_{j=1}^L \frac{N_j}{N} m_j + \sum_{i=1}^L \frac{N_i}{N} \sum_{j=1}^L \frac{N_j}{N} m_j m_j^T \right) \quad (\because \sum_{j=1}^L \frac{N_j}{N} = 1)
 \end{aligned}$$

$$\sum_{i=1}^L \frac{N_i}{N} m_i = m_0$$


$$\begin{aligned}
 S_b^{LDA} &= \frac{1}{2} \left( \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - \sum_{i=1}^L \frac{N_i}{N} m_i \sum_{j=1}^L \frac{N_j}{N} m_j^T \right. \\
 &\quad \left. - \sum_{i=1}^L \frac{N_i}{N} m_i^T \sum_{j=1}^L \frac{N_j}{N} m_j + \sum_{i=1}^L \frac{N_i}{N} m_j m_j^T \right) \\
 &= \frac{1}{2} \left( \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - m_0 m_0^T - m_0 m_0^T + \sum_{j=1}^L \frac{N_j}{N} m_j m_j^T \right) \\
 &= \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - m_0 m_0^T \\
 &= \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - m_0 m_0^T - m_0 m_0^T + m_0 m_0^T \\
 &= \sum_{i=1}^L \frac{N_i}{N} m_i m_i^T - \sum_{i=1}^L \frac{N_i}{N} m_i m_0^T - m_0 \sum_{i=1}^L \frac{N_i}{N} m_i^T + \sum_{i=1}^L \frac{N_i}{N} m_0 m_0^T \\
 &= \sum_{i=1}^L \frac{N_i}{N} (m_i m_i^T - m_i m_0^T - m_0 m_i^T + m_0 m_0^T) \\
 &= \sum_{i=1}^L \frac{N_i}{N} (m_i - m_0)(m_i^T - m_0^T) \\
 &= \sum_{i=1}^L \frac{N_i}{N} (m_i - m_0)(m_i - m_0)^T
 \end{aligned}$$

## 02 LDA의 이해

### - Fisher's linear discriminant

1) 클래스 간의 거리의 합

$$\begin{aligned} S_b^{LDA} &= \sum_{i=1}^{L-1} \sum_{j=i+1}^L \frac{N_i}{N} \frac{N_j}{N} (m_i - m_j)(m_i - m_j)^T \\ &= \sum_{i=1}^L \frac{N_i}{N} (m_i - m_0)(m_i - m_0)^T \end{aligned}$$



Between-class scatter matrix : 각 클래스 평균 사이의 거리들의 합은 각 클래스 평균과 전체 평균간의 거리들의 합과 같다.

## 02 LDA의 이해

### - Fisher's linear discriminant

#### 1) 각 클래스 내의 분산의 합

클래스  $i$ 에 속하는 데이터 포인트들의 사상의 분산

$$\sum_{j=1}^{N_i} \frac{1}{N} (v^T x_j^{(i)} - \overline{m_i})^2$$


모든 클래스의 사상의 분산의 합

$$\begin{aligned} & \sum_{i=1}^L \sum_{j=1}^{N_i} \frac{1}{N} (v^T x_j^{(i)} - \overline{m_i})^2 \\ &= \sum_{i=1}^L \sum_{j=1}^{N_i} \frac{1}{N} (v^T x_j^{(i)} - v^T m_i) (v^T x_j^{(i)} - v^T m_i)^T \quad (\because \overline{m_i} = v^T m_i) \\ &= \sum_{i=1}^L \sum_{j=1}^{N_i} \frac{1}{N} v^T (x_j^{(i)} - m_i) (x_j^{(i)} - m_i)^T v \\ &= v^T \left( \sum_{i=1}^L \sum_{j=1}^{N_i} \frac{1}{N} (x_j^{(i)} - m_i) (x_j^{(i)} - m_i)^T \right) v \\ &= v^T S_w^{LDA} v \end{aligned}$$

→ Within-class scatter matrix

$L$ : 클래스 수  
 $N_i$ : 클래스  $i$  내 샘플의 개수  
 $N$ : 전체 샘플의 개수  
 $x_j^{(i)}$ : 클래스  $i$  내  $j$  번째 샘플

$$S_w^{LDA} = \sum_{i=1}^L \sum_{j=1}^{N_i} \frac{1}{N} (x_j^{(i)} - m_i) (x_j^{(i)} - m_i)^T$$



within-class scatter matrix: 각 클래스 내의 데이터포인트들과 각 클래스의 평균 사이의 거리를 모두 더한다.

## 02 LDA의 이해

### - Fisher's linear discriminant

목적함수를  $v$ 에 대해 미분하고 0을 가지는  $v$ 를 찾는다!!

$$\begin{aligned} v &= \arg \max_{v \in R^d} \frac{v^T S_b^{LDA} v}{v^T S_w^{LDA} v} \\ &= \arg \max_{v^T S_w^{LDA} v = 1} v^T S_b^{LDA} v \end{aligned}$$

$$S_b^{LDA} v = \lambda S_w^{LDA} v$$

$$(S_w^{LDA})^{-1} S_b^{LDA} v = \lambda v$$

$(S_w^{LDA})^{-1} S_b^{LDA}$ 의 고유 값(eigen value)과 고유 벡터(eigen vector)를 찾아준다.


$$S_w^T S_b = [e_1 \cdots e_n] \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \cdots & \cdots & \cdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^T \\ \cdots \\ e_n^T \end{bmatrix}$$

가장 높은 고유 값을 가지는 고유 벡터가 사상 벡터가 된다.

## 02 LDA의 이해

### - Bayes's rule

LDA 가정 : 데이터 분포가 **다변량 정규분포(multivariate normal distribution)**



- $P(W_i|x)$ 는 새로운 데이터  $x$ 가 주어졌을 때(=정답 범주를 모를 때=예측할 때)  $W_i$ 일 확률, 즉 검증데이터가 특정 범주에 할당하기 위한 스코어를 의미합니다. 범주 분류를 위한 확률(스코어)를 내어주는 함수를 **판별함수(discriminant function)**라고 합니다
- 판별함수는 다변량 정규분포를 따른다고 가정한다.
- 두 범주의 판별함수가 같아지는 선형식을 구하고 선형식의 coefficient를 구하면 위에서 구한 사상벡터가 나온다.

$$\begin{aligned} P(W_i|x) &= \frac{P(x|W_i)P(W_i)}{P(x)} \\ &= \frac{P(x|W_i)P(W_i)}{P(x|W_1)P(W_1) + P(x|W_2)P(W_2)} \end{aligned}$$

# 01

## Linear Discriminant Analysis(LDA) 개요

- 선형판별분석
- LDA vs PCA

# 02

## LDA의 이해

- Fisher's linear discriminant
- Basysian rule

# 03

## LDA 실습

- Sklearn, iris dataset을 이용한 실습

감사합니다

